

دانشکده علوم ریاضی

تشخیص ناهنجاری ضربان قلب با اتوانکودر روی ECG۵۰۰۰ با قاعده‌ی آستانه‌گذاری بودجه‌ی هشدار کاذب

نام استاد: دکتر هادی فراهانی

نام دستیار: آقای مبین نثاری

نام دانشجو: ناهید حاتمی بلاسی

شماره دانشجویی: ۴۰۴۴۲۲۲۰۷

تابستان ۱۴۰۵

۱.مقدمه

تشخیص خودکار ضربان‌های غیرطبیعی قلب یکی از کاربردهای مهم یادگیری ماشین در پزشکی است. در بسیاری از مسائل دسته‌بندی، تعداد نمونه‌های هر کلاس تقریباً متعادل است؛ اما در اینجا معمولاً نمونه‌های غیرطبیعی بسیار کمتر از نمونه‌های طبیعی‌اند، و از سوی دیگر هم تضمینی وجود ندارد که همه الگوهای غیرطبیعی از قبل در داده دیده شده باشند. به همین دلیل، یکی از رویکردهای رایج این است که مدل فقط روی ضربان‌های طبیعی آموزش ببیند و سپس هر نمونه‌ای که مدل نتواند آن را خوب بازسازی کند، به‌عنوان ناهنجاری در نظر گرفته شود. در این میان، اتوانکودر مدلی مناسب است که می‌تواند الگوی طبیعی را فشرده کرده و دوباره بازسازی کند، اما در بازسازی نمونه‌هایی که ندیده است معمولاً عملکرد ضعیف‌تری دارد. همچنین این رویکرد یک چالش مهم دارد که اگر اتوانکودر بیش از حد قدرتمند باشد، ممکن است حتی ناهنجاری‌ها را هم به‌خوبی بازسازی کند و در نتیجه توان تشخیص خود را از دست بدهد. این تضاد، یکی از محورهای اصلی این گزارش نیز هست.

۲. مسئله و هدف پژوهش

در این پژوهش، یک اتوانکودر Dense روی مجموعه‌داده ECG۵۰۰۰ فقط با ضربان‌های طبیعی آموزش داده می‌شود. سپس برای هر ضربان جدید، خطای بازسازی (reconstruction MSE) محاسبه می‌شود و نمونه‌هایی که خطای آن‌ها از یک آستانه مشخص بیشتر باشد، به‌عنوان ناهنجاری علامت‌گذاری می‌شوند. از آنجا که کلاس‌ها به‌شدت نامتوازن‌اند و بیشتر داده‌ها طبیعی هستند، معیار accuracy به‌تنهایی می‌تواند گمراه‌کننده باشد؛ به همین دلیل، معیارهای Precision، Recall و F۱ به‌عنوان شاخص‌های اصلی گزارش می‌شوند.

هدف اصلی این پژوهش فقط آموزش یک اتوانکودر و انتخاب یک آستانه ثابت، مثل صدک ۹۵، نیست. نوآوری اصلی این کار، طراحی یک قاعده آستانه‌گذاری غیرساده و قابل توجیه است که به‌جای تکیه بر یک صدک دلخواه، آستانه را بر اساس یک بودجه صریح و مشخص برای نرخ هشدار کاذب انتخاب می‌کند. سپس اثر این انتخاب بر Precision، Recall و همچنین بر تشخیص زیرنوع‌های مختلف ناهنجاری بررسی می‌شود.

۳. داده پژوهش

۱.۳ مجموعه داده

مجموعه‌داده مورد استفاده، ECG ۵۰۰۰ است که شامل ۵۰۰۰ توالی ضربان قلب با طول ۱۴۰ نمونه می‌شود. این داده‌ها به کلاس ۱ (طبیعی) و کلاس‌های ۲ تا ۵ (چهار زیرنوع غیرطبیعی) برچسب‌گذاری شده‌اند. تقسیم داده ابتدا فقط ضربان‌های طبیعی کلاس ۱ از مجموعه train اصلی برای آموزش اتوانکودر استفاده می‌شوند؛ بنابراین اتوانکودر هرگز نمونه غیرطبیعی را در آموزش نمی‌بیند. همچنین داده‌های طبیعی train با نسبت ۲۰/۸۰ به دو بخش train-normal و validation-normal تقسیم می‌شوند.مجموعه test اصلی فقط برای ارزیابی نهایی استفاده می‌شود؛ نه برای آموزش، نه برای انتخاب مدل، و نه برای تعیین آستانه. در test، کلاس ۱ طبیعی و کلاس‌های ۲ تا ۵ غیرطبیعی در نظر گرفته می‌شوند.

جدول ۱_تقسیم داده

مجموعه	تعداد نمونه	توضیح
train-normal	۲۳۳	برای آموزش اتوانکودر
validation-normal	۵۹	فقط برای انتخاب threshold — هرگز برای آموزش
test — طبیعی (کلاس ۱)	۲,۶۲۷	ارزیابی نهایی
test — کلاس ۲ (غیرطبیعی)	۱,۵۹۰	ارزیابی نهایی، به‌تفکیک subtype
test — کلاس ۳ (غیرطبیعی)	۸۶	ارزیابی نهایی، به‌تفکیک subtype
test — کلاس ۴ (غیرطبیعی)	۱۷۵	ارزیابی نهایی، به‌تفکیک subtype
test — کلاس ۵ (غیرطبیعی)	۲۲	ارزیابی نهایی، به‌تفکیک subtype
test — کل	۴,۵۰۰	۲۶۲۷ طبیعی + ۱۸۷۳ غیرطبیعی

همچنین در مجموعه validation-normal فقط ۵۹ نمونه دارد؛ یعنی اندازه آن بسیار کوچک است و این موضوع می‌تواند بر پایداری هر قاعده آستانه‌گذاری اثر بگذارد و می‌توان از روش‌هایی نظیر Bootstrap استفاده نمود.

۴. پیش‌پردازش

ابتدا نرمال‌سازی که میانگین و انحراف معیار فقط از داده‌های train-normal محاسبه می‌شود و همان تبدیل روی validation-normal و test اعمال می‌گردد؛ این کار برای جلوگیری از نشت اطلاعات از سایر مجموعه‌ها انجام می‌شود.پس از نرمال‌سازی، داده‌ها از نظر وجود مقادیر NaN و Inf بررسی می‌شوند تا از سلامت آن‌ها اطمینان حاصل شود. ابتدا داده‌ها به شکل (samples, ۱۴۰ , ۱) در می‌آیند و سپس برای ورودی اتوانکودر Dense به (samples, ۱۴۰) تبدیل می‌شوند.

۵. روش

۵.۱ معماری اتوانکدر و آموزش

مدل مورد استفاده یک اتوانکودر Dense ساده و تمام‌متصل است. این انتخاب عمدی بوده تا یک خط‌مبنای روشن، قابل‌فهم و کم‌ظرفیت داشته باشیم، نه یک معماری پیچیده که کار با آن دشوار است.

جدول ۲- معماری اتوانکودر

لایه	ابعاد خروجی	فعال‌سازی
Input	۱۴۰	—
enc_dense_٦٤	۶۴	ReLU
enc_dense_۳۲	۳۲	ReLU
bottleneck	۸	ReLU
dec_dense_۳۲	۳۲	ReLU
dec_dense_٦٤	۶۴	ReLU
reconstruction (خروجی)	۱۴۰	خطی (linear)

مجموع پارامترهای قابل آموزش: ۲۲۸۶۸

گلوگاه ۸بعدی عمداً کوچک انتخاب شده است؛ به این معنا که یک ورودی ۱۴۰بعدی باید از یک نمایش ۸بعدی بازسازی شود. در نتیجه، مدل مجبور است الگوی کلی ضربان طبیعی را فشرده کند، نه اینکه صرفاً داده را به‌صورت سطحی کپی کند. تنظیمات آموزش نیز به‌صورت بهینه‌ساز Adam با نرخ یادگیری پیش‌فرض و دارای تابع زیان MSE و حداکثر ۲۰۰ epoch batch size ۶۴ می‌باشد.

۲.۵ امتیازدهی و آستانه پایه

امتیاز ناهنجاری هر نمونه برابر با خطای بازسازی آن است:

$$error_i = mean\left((x_i - \hat{x}_i)^2\right)$$

این مقدار روی ۱۴۰ نقطه سیگنال محاسبه می‌شود و آستانه پایه (`baseline_p=۹۵`) طبق رویکرد رایج این نوع مسئله، برابر با صدک ۹۵ خطای validation-normal تعریف شده است.

جدول ۳ — آمار خطای بازسازی

مجموعه	میانگین خطا	انحراف‌معیار
validation-normal (n=۵۹)	۰.۲۵۴۹۲	۰.۹۲۸۱۳
test-normal (n=۲,٦۲۷)	۰.۱۹۷۰۷	۰.۴۸۴۱۱
test-abnormal (n=۱,۸۷۳)	۱.۹۴۷۱۸	۱.۵۸۳۸۹

بنابراین $baseline_p{}^{۹۵} = ۰.۳۵۱٦۲۰$

این آستانه روی خود validation-normal نرخ هشدار کاذب ۵.۰۸٪ ایجاد می‌کند؛ یعنی ۳ نمونه از ۵۹ نمونه طبیعی در اعتبارسنجی به اشتباه بالاتر از آستانه قرار می‌گیرند.

۶. مشارکت خلاقانه

ایده اصلی این بخش از نتایج همین baseline به دست آمد. با threshold = ۰/۳۵۱۶۲۰، مقدار Recall بسیار بالا بود (۹۹.۶۸٪)، اما در عین حال مدل روی تنها ۲۶۲۷ نمونه طبیعی test، تعداد ۲۰۱ False Positive تولید کرد.

این نتیجه یک پرسش مهم ایجاد کرد که آیا این threshold برای کاربردهای عملی، به‌خصوص در سناریوهایی که هشدار کاذب هزینه‌بر است، بیش از حد پایین نیست؟ برای مثال، در کاربردهای پزشکی، آلارم‌های مکرر می‌توانند آزاردهنده و حتی مشکل‌ساز باشند. از طرف دیگر، بالا بردن دستی threshold تا جایی که بهترین F۱ را روی test بدهد، از نظر علمی روش درستی نیست، چون در عمل از اطلاعات test برای انتخاب مدل استفاده می‌شود و این همان test leakage است.

برای حل این مسئله، در این پژوهش یک قاعده آستانه‌گذاری صریح تعریف شد که فقط از validation-normal استفاده می‌کند و بر پایه یک بودجه از پیش تعیین‌شده برای نرخ هشدار کاذب عمل می‌کند. بنابراین، آستانه نه به‌صورت یک صدک دلخواه، بلکه بر اساس یک پارامتر صریح به نام α انتخاب می‌شود یعنی به‌صورت زیر

$$T^{*}(\alpha) = \min\{T \mid mean(val_normal_errors > T) \leq \alpha\}$$

است. همچنین در این قاعده، از میان همه آستانه‌هایی که بودجه α را رعایت می‌کنند، کوچک‌ترین threshold انتخاب می‌شود تا حساسیت مدل نسبت به ناهنجاری‌ها تا حد امکان حفظ شود.این روش برای پنج مقدار مختلف از بودجه هشدار کاذب

$$\alpha \in \{۰.۱۰, ۰.۰۷, ۰.۰۵, ۰.۰۳۵, ۰.۰۲\}$$

ارزیابی شده و با baseline_p=۹۵ مقایسه می‌شود. همچنین، چون validation-normal فقط ۵۹ نمونه دارد، یک آزمون پایداری bootstrap نیز انجام می‌شود تا پایداری threshold بررسی شود.

۷. فرضیه‌های پژوهش

۷.۱ فرضیه اصلی

یک قاعده آستانه‌گذاری مبتنی بر بودجه هشدار کاذب $T^{*}(\alpha)$ که فقط از خطاهای بازسازی validation-normal ساخته می‌شود، می‌تواند به‌صورت سیستماتیک بین کنترل نرخ هشدار کاذب و حفظ Recall برای ناهنجاری‌ها trade-off ایجاد کند. به این صورت که با کاهشα و سخت‌گیرانه‌تر شدن بودجه، Precision افزایش یابد و Recall کاهش پیدا کند، و این trade-off شفاف‌تر و قابل‌توجیه‌تر از انتخاب یک صدک ثابت و دلخواه، مثل صدک ۹۵، باشد.

۷.۲ فرضیه فرعی

با محافظه‌کارانه‌تر شدن threshold و کاهش هشدارهای کاذب، افت Recall به‌طور یکسان روی همه subtypeها توزیع نمی‌شود. انتظار می‌رود این افت بیشتر روی subtypeهای حساس‌تر، به‌ویژه کلاس ۵ که در baseline کمترین Recall را داشته است، دیده شود.

۸. پیکربندی و ارزیابی

۱.۸ پیکربندی آموزش

اتوانکودر با بهینه‌ساز Adam و تابع زیان MSE آموزش دیده است. حداکثر تعداد epoch برابر ۲۰۰ و اندازه batch برابر ۶۴ است. برای جلوگیری از بیش‌آموزشی، EarlyStopping بر پایه val_loss با patience=۵ و restore_best_weights=True فعال بوده است. برای تکرارپذیری کامل آزمایش‌ها، seed تصادفی برابر ۴۲ در تمام بخش‌ها ثابت نگه داشته شده است؛ از جمله در numpy، random و برای مرحله bootstrap نیز یک RandomState اختصاصی در نظر گرفته شده است. نکته مهم این است که قاعده آستانه‌گذاری بودجه هشدار کاذب که مشارکت اصلی این پژوهش است، هیچ retrainingای روی اتوانکودر انجام نمی‌دهد. این قاعده کاملاً post-hoc است و فقط از خطاهای بازسازی یک مدل از پیش آموزش‌دیده استفاده می‌کند. این تفکیک عمدی است تا مشخص باشد بهبود عملکرد از خود معماری ناشی نمی‌شود، بلکه کاملاً از قاعده انتخاب threshold نشئت می‌گیرد.

۸. ۲ خطوط مبنای مقایسه

برای اینکه برتری قاعده پیشنهادی به درستی سنجیده شود، سه سطح خط مبنا در نظر گرفته شده است.

جدول ۴ — خطوط مبنای مقایسه

خط مبنا	توصیف
baseline_p۹۵	آستانه‌ی ثابت = صدک ۹۵ ام خطای validation-normal روش رایج و پیشین
One-Class SVM (stretch)	فیت‌شده فقط روی train-normal، با همان قاعده‌ی T*(α) روی امتیاز decision_function ارزیابی می‌شود.
Isolation Forest (stretch)	فیت‌شده فقط روی train-normal، با همان قاعده‌ی T*(α) روی امتیاز decision_function ارزیابی می‌شود.

نکته مهم در طراحی این مقایسه این است که هر دو خط مبنای stretch نیز دقیقاً مثل اتوانکودر فقط روی train-normal فیت می‌شوند، نه روی داده غیرطبیعی یا test. آستانه آن‌ها هم دقیقاً با همان قاعده T*(α) که مشارکت اصلی این پروژه است انتخاب می‌شود. به عبارت دیگر، مقایسه بین سه خانواده مدل (Autoencoder، OCSVM و Isolation Forest) با یک قاعده انتخاب threshold یکسان انجام می‌شود، نه با سه رویه نامرتبط انجام شود.

۹. معیارهای ارزیابی

۱.۹ معیارهای کلی

معیارهای Precision، Recall، F۱ و Accuracy روی مجموعه test گزارش می‌شوند. با توجه به نامتوازن بودن شدید کلاس‌ها ۲,۶۲۷ نمونه طبیعی در برابر ۱,۸۷۳ نمونه غیرطبیعی معیار Accuracy به تنهایی گمراه‌کننده است. بنابراین Precision، Recall و F۱ معیارهای اصلی تصمیم‌گیری هستند. علاوه بر این، برای baseline معیارهای ROC-AUC و PR-AUC نیز محاسبه شده‌اند تا تصویری مستقل از انتخاب threshold نیز در دسترس باشد.

۲.۹ معیارهای تفکیکی

برای هر threshold، تعداد False Positive و False Negative، و همچنین Recall به تفکیک چهار subtype غیرطبیعی (کلاس‌های ۲ تا ۵ در ۵۰۰۰ECG) گزارش می‌شود. این گزارش تفکیکی برای پاسخ به این سؤال ضروری است که کدام نوع ناهنجاری از دست می‌رود.

۹. ۳ پایداری آستانه

از آنجا که validation-normal فقط ۵۹ نمونه دارد، پایداری خود threshold یک نگرانی واقعی است. برای بررسی این موضوع، نمونه‌گیری bootstrap با ۱,۰۰۰ تکرار روی خطاهای validation-normal انجام می‌شود. هر تکرار با جایگذاری و با اندازه n = ۵۹ انجام می‌گیرد و قاعده $T^*(\alpha)$= ۰.۰۳۵ روی هر نمونه دوباره محاسبه می‌شود تا توزیع احتمالی threshold به دست آید.

۴.۹ محیط اجرا

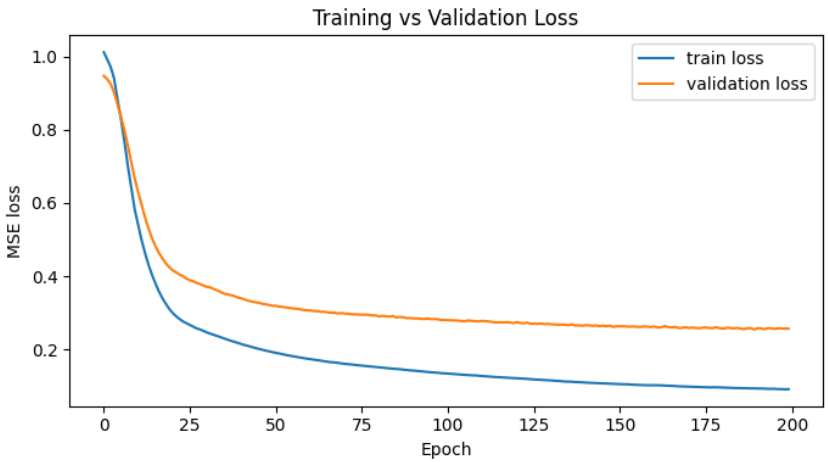
پیاده‌سازی روی Google Colab اجرا شده است و نسخه کتابخانه‌ها به شکل زیر پین شده است.

جدول۵ – نسخه کتابخانه‌ها

کتابخانه	نسخه
Tensorflow	۲،۱۶،۱
scikit-learn	۱،۴،۲
Pandas	۲،۲،۲
Numpy	۱،۲۶،۴
Matplotlib	۳،۸،۴

۱۰. نتایج

۱.۱۰ نتایج baseline



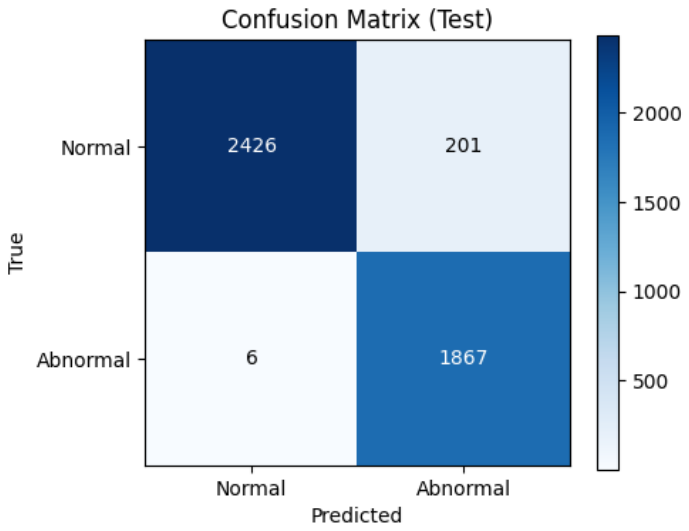
شکل ۱- بررسی روند آموزش baseline

در شکل ۱،نمودار روند تغییرات خطای آموزش (Train Loss) و اعتبارسنجی (Validation Loss) را در طول ۲۰۰ دوره آموزشی (Epoch) نشان می‌دهد. همان‌طور که در نمودار مشاهده می‌شود، val_loss تا حدود دوره ۵۰ به‌سرعت کاهش می‌یابد و پس از آن با شیب بسیار ملایم‌تری تا پایان روند آموزش (دوره ۲۰۰) ادامه پیدا می‌کند. فاصله کم بین train_loss و val_loss در انتهای آموزش (۰.۰۹۲ در برابر ۰.۲۵۷) نشان می‌دهد که مدل روی داده‌های طبیعی به‌خوبی Generalize کرده و نشانه آشکاری از Overfitting شدید مشاهده نمی‌شود.

جدول ۶ — عملکرد baseline_p۹۵ روی مجموعه تست

معیار	مقدار (threshold = ۰,۳۵۱۶۲۰)
Precision	۰.۹۰۲۸
Recall	۰.۹۹۶۸
F۱	۰.۹۴۷۵
Accuracy	۰.۹۵۴۰
ROC-AUC	۰.۹۸۶۷
PR-AUC	۰.۹۵۲۶

همان‌طور که از این نتایج پیداست، مدل توانسته در حالت پایه با آستانه صدک ۹۵، مقدار Recall بسیار بالایی را ثبت کند که نشان‌دهنده شناسایی موفق اکثر ناهنجاری‌هاست. با این حال، همان‌طور که قبلاً اشاره شد، این دقت بالا لزوماً به معنای عملکرد بهینه در سناریوهای عملی نیست، چرا که نرخ هشدار کاذب باید با دقت بیشتری کنترل شود.



شکل۲- ماتریس درهم‌ریختگی زیر، عملکرد مدل پایه (baseline_p۹۵) را روی مجموعه تست

تحلیل این ماتریس نشان می‌دهد که با آستانه پایه، مقدار Recall بسیار بالاست (۹۹.۶۸٪) و تنها ۶ مورد ناهنجاری از زیر دست مدل در رفته است (False Negative). اما این حساسیت بالا هزینه‌ای هم داشته است: ۲۰۱ مورد هشدار کاذب (False Positive) روی ۲,۶۲۷ نمونه طبیعی ایجاد شده است. همین مشاهده، یعنی بالا بودن تعداد هشدارهای کاذب در کاربردهای حساس پزشکی، انگیزه اصلی برای ارائه مشارکت این پژوهش (طراحی قاعده بودجه‌بندی هشدار کاذب) بوده است.

۱۰. ۲ نتایج قاعده بودجه هشدار کاذب

در این بخش، تأثیر انتخاب پارامتر α (بودجه هشدار کاذب) بر مقدار آستانه نهایی بررسی شده است. نتایج حاصل از اعمال این قاعده روی داده‌های اعتبارسنجی در جدول زیر آمده است:

جدول ۷ — آستانه انتخاب‌شده به‌ازای هر بودجه (α)

A	Threshold	validation روی FPR	n بالاتر آستانه
۰.۱۰	۰.۲۷۵۷۳۹	۰.۰۸۴۷۴۶	۵
۰.۰۷	۰.۲۸۷۶۷۱	۰.۰۶۷۷۹۷	۴
۰.۰۵	۰.۵۲۸۳۶۵	۰.۰۳۳۸۹۸	۲
۰.۰۳۵	۰.۵۲۸۳۶۵	۰.۰۳۳۸۹۸	۲
۰.۰۲	۰.۷۴۲۲۵۵	۰.۰۱۶۹۴۹	۱

در جدول ۷ مشاهده می‌شود، از آنجا که مجموعه validationnormal کوچک است (فقط ۵۹ نمونه)، مقادیر α=۰,۰۵ و α=۰,۰۳۵ به یک آستانه کاملاً یکسان ختم شده‌اند. این موضوع نشان می‌دهد که روی نمونه‌های کوچک، نرخ هشدار کاذب (FPR) فقط می‌تواند مقادیر گسسته‌ای داشته باشد که این خود یکی از محدودیت‌های تحلیل بر روی داده‌های کم‌حجم است.

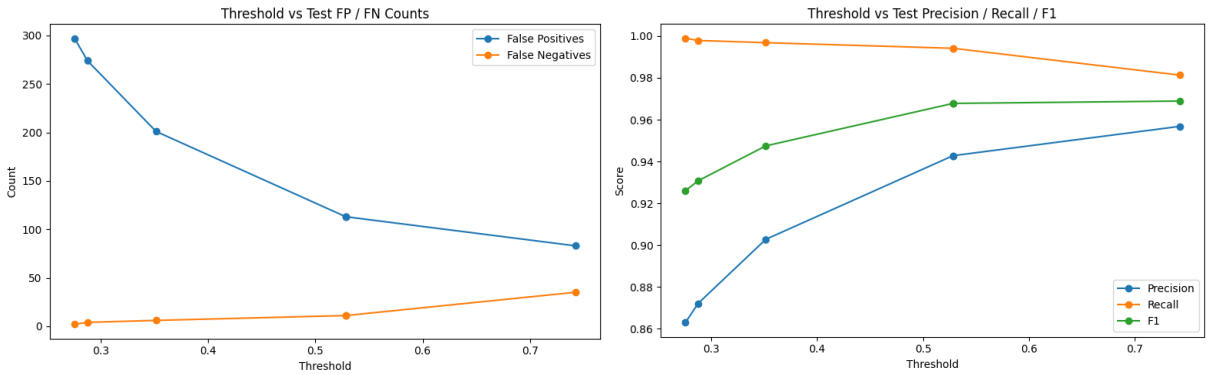
جدول۸- مقایسه کامل روی تست (مرتب‌شده بر اساس مقدار آستانه)

روش	Threshold	Precision	Recall	F۱	FP	FN
α=۰,۱۰	۰.۲۷۵۷۳۹	۰.۸۶۳۰	۰.۹۹۸۹	۰.۹۲۶۰	۲۹۷	۲
α=۰,۰۷	۰.۲۸۷۶۷۱	۰.۸۷۲۱	۰.۹۹۷۹	۰.۹۳۰۸	۲۷۴	۴
baseline_p۹۵	۰.۳۵۱۶۲۰	۰.۹۰۲۸	۰.۹۹۶۸	۰.۹۴۷۵	۲۰۱	۶
α=۰,۰۵ / ۰,۰۳۵	۰.۵۲۸۳۶۵	۰.۹۴۲۸	۰.۹۹۴۱	۰.۹۶۷۸	۱۱۳	۱۱
α=۰,۰۲	۰.۷۴۲۲۵۵	۰.۹۵۶۸	۰.۹۸۱۳	۰.۹۶۸۹	۸۳	۳۵

در جدول۸ با حرکت از α=۰,۱۰به سمت α=۰,۰۲، مدل محافظه‌کارتر می‌شود. همچنین تعداد هشدارهای کاذب (FP) از ۲۹۷ به ۸۳ کاهش یافته که باعث افزایش چشمگیر Precision شده است. اگرچه مقدار Recall اندکی افت کرده (از ٪۹۹.۸۹ به ٪۹۸.۱۳)، اما مقدار F۱ بهبود یافته و به بالاترین حد خود (۰.۹۶۸۹) رسیده است. این نتایج فرضیه اصلی پژوهش مبنی بر امکان ایجاد یک Trade-off شفاف و سیستماتیک را تأیید می‌کند.

۱۰. ۳ بررسی فرضیه‌های پژوهش و تحلیل نمودارها

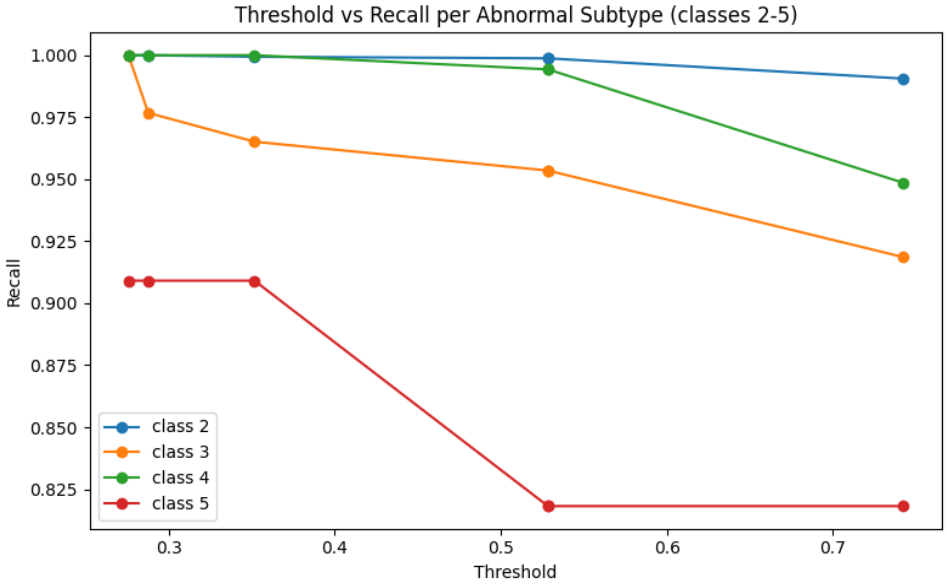
روند تغییرات معیارها و فراوانی خطاهای مدل در نمودارهای زیر به تصویر کشیده شده است.



شکل۳- تغییرات معیارهای Recall، Precision و F۱ در برابر آستانه(در سمت راست)و فراوانی خطاهای مثبت کاذب (FP) و منفی کاذب (FN) در برابر آستانه (در سمت چپ)

در شکل ۳، نمودارها به‌وضوح فرضیه اصلی پژوهش را تأیید می‌کند. با کاهش بودجه خطا (α از ۰.۱۰ به ۰.۰۲)، مقدار آستانه به‌طور یکنواخت افزایش می‌یابد. این افزایش آستانه منجر به کاهش مداوم و یکنواخت هشدارهای کاذب (FP) از ۲۹۷ به ۸۳ می‌شود که افزایش معیار Precision از ٪۸۶.۳ به ٪۹۵.۷ را به همراه دارد. در مقابل، تعداد منفی‌های کاذب (FN) نیز به‌طور یکنواخت از ۲ به ۳۵ افزایش می‌یابد که به معنای کاهش اندک Recall از ٪۹۹.۹ به ٪۹۸.۱ است. این رفتار سیستماتیک و پیش‌بینی‌پذیر نشان می‌دهد که قاعده آستانه‌گذاری پیشنهادی برخلاف یک صدک ثابت و دلخواه، کنترل صریح و قابل‌توجیهی روی نرخ هشدارهای کاذب (FPR) فراهم می‌کند.

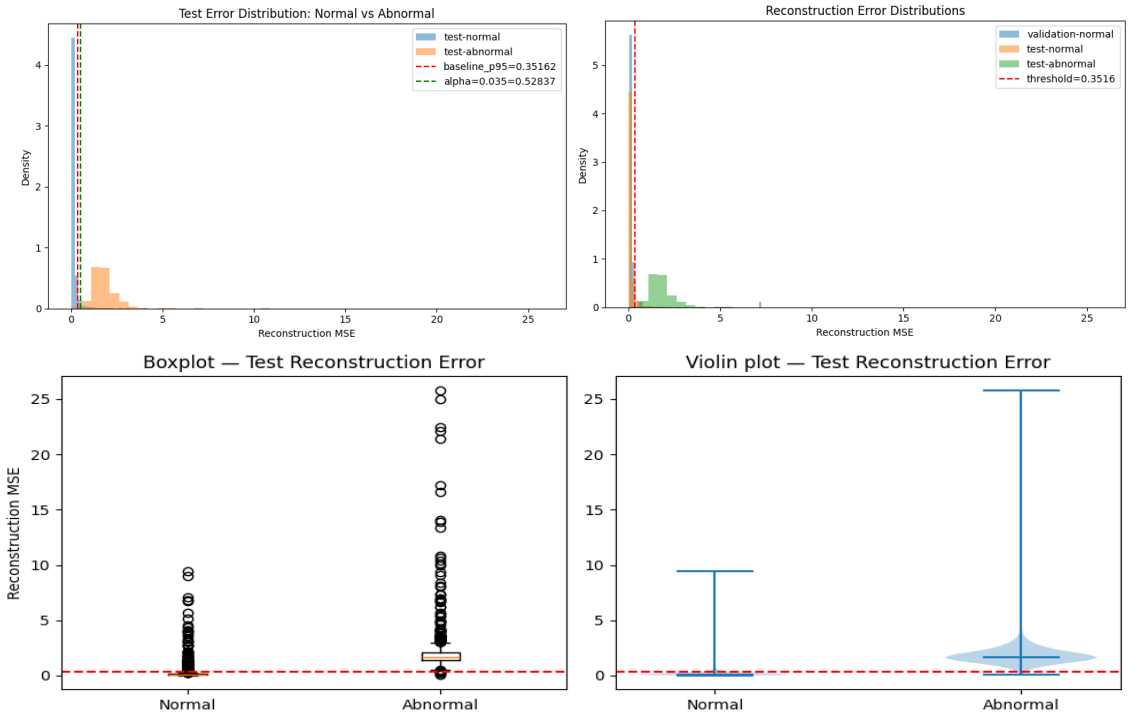
۴.۱۰ بررسی فرضیه فرعی و اثر آستانه بر زیرنوع‌های ناهنجاری



شکل۴- میزان Recall به تفکیک چهار زیر نوع ناهنجاری در برابر تغییرات آستانه

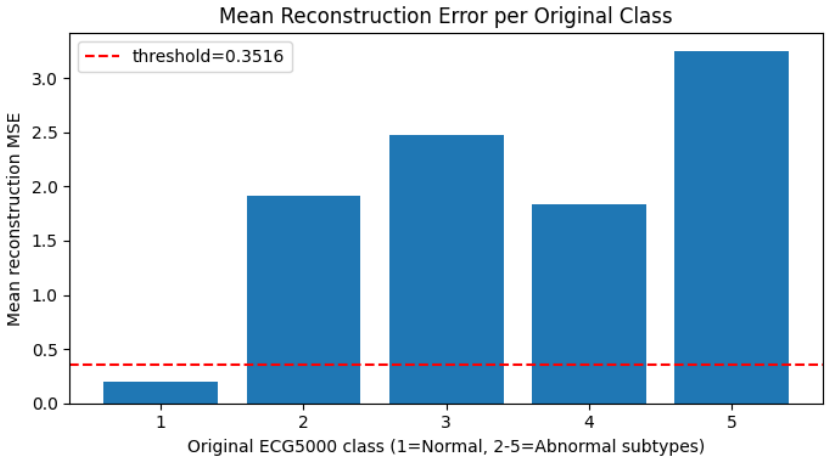
در شکل۴ همان‌طور که مشخص است، میزان حساسیت مدل روی کلاس‌های ۲ و ۴ در تمام محدوده تغییرات آستانه بسیار بالا و نزدیک به ۱.۰ باقی می‌ماند که نشان می‌دهد این دو زیرنوع ناهنجاری الگوهای مشخصی داشته و تشخیص آن‌ها ساده است.در مقابل، زیرنوع‌های دیگر رفتار متفاوتی نشان می‌دهند که در کلاس ۵ که در آستانه پایه (baseline_p ۹۵) دارای Recall برابر با ۰.۹۰۹ بود، با سخت‌گیرانه‌تر شدن بودجه خطا (α=۰.۰۲) به ۰.۸۱۸ افت می‌کند. کلاس ۳ نیز از مقدار اولیه ۰.۹۶۵ در مدل پایه، به ۰.۹۱۹ کاهش می‌یابد. این نتایج نشان می‌دهد که هزینه افزایش آستانه و محافظه‌کارتر شدن مدل به‌طور یکسان توزیع نمی‌شود و بیشترین آسیب و افت حساسیت متوجه کلاس‌های ۳ و ۵ (به‌ویژه کلاس ۵) می‌گردد.

۴.۱۰ تحلیل آماری توزیع خطای بازسازی



شکل۵- نمودار توزیع خطای تست و نمودارهای جعبه‌ای و ویولنی

در شکل۵، نمودار توزیع خطای تیست و نمودارهای جعبه‌ای/ویولنی تفاوت معنادار آماری بین دو گروه را تایید می‌کنند که میانگین خطای نمونه‌های غیرطبیعی (۱.۹۴۷) تقریباً ۱۰ برابر میانگین خطای نمونه‌های طبیعی (۰.۱۹۷) است. همچنین فاصله قابل‌توجهی بین میانه‌های دو توزیع (۱.۵۸۶) مشاهده می‌شود. با این حال، علی‌رغم این تفاوت در شاخص‌های مرکزی، دو توزیع دارای هم‌پوشانی (Overlap) بسیار گسترده‌ای هستند. در بازه هم‌پوشانی [۰.۰۶,۹.۴۱]، تعداد ۲,۳۳۹ نمونه طبیعی (از مجموع ۲,۶۲۷) و ۱,۸۵۸ نمونه غیرطبیعی (از مجموع ۱,۸۷۳) قرار گرفته‌اند. به عبارت دیگر، اکثریت در هر دو گروه در یک ناحیه مشترک از خطا حضور دارند و جدایی کامل توزیع‌ها تنها در دم‌های بسیار دور (Extremes) رخ می‌دهد. این یافته آماری توضیح می‌دهد که چرا با هیچ‌یک از آستانه‌های انتخاب‌شده، نمی‌توان به‌طور هم‌زمان به دقت (Precision) و حساسیت (Recall) نزدیک به ۱۰۰٪ دست یافت؛ چرا که هرگونه تلاش برای حذف هشدارهای کاذب، اما بخشی از بدنه اصلی توزیع ناهنجاری را نیز از دست می‌دهد.

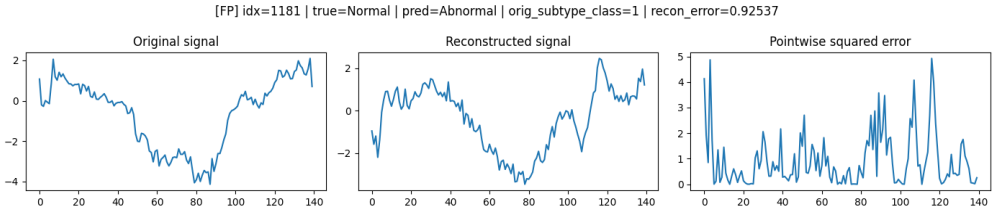


شکل۶- میانگین خطا بازسازی به تفکیک کلاس اصلی

نمودار میانگین خطا برای هر کلاس بینش دقیق‌تری از رفتار اتوانکودر در برابر الگوهای مختلف ارائه می‌دهد. در شکل ۶مشاهده می‌شود که کلاس ۵ با وجود تعداد نمونه بسیار کم (فقط ۲۲ نمونه در کل مجموعه تست)، بالاترین میانگین خطای بازسازی (۳.۲۵) را به خود اختصاص داده است. این موضوع نشان می‌دهد که الگوی ضربان در این کلاس، بیشترین فاصله را از فضای ویژگی‌های یادگرفته‌شده توسط اتوانکودر (که فقط روی کلاس ۱ آموزش دیده) دارد.نکته حائز اهمیت این است که اگرچه میانگین خطای کلاس ۵ بالاست، اما همان‌طور که در نمودار ویولنی در شکل۵ و تحلیل حساسیت قبلی دیدیم، این کلاس پراکندگی (Variance) بالایی نیز دارد. وجود نمونه‌هایی با خطای بسیار پایین در این کلاس باعث می‌شود که با افزایش آستانه (در بودجه‌های α سخت‌گیرانه)، Recall این کلاس زودتر از بقیه دچار افت شود. این ناهنجاری‌های شبیه به نرمال (Near-normal Anomalies) چالش اصلی مدل در تشخیص دقیق کلاس ۵ محسوب می‌شوند.

۵.۱۰ تحلیل یک نمونه خطای منفی کاذب

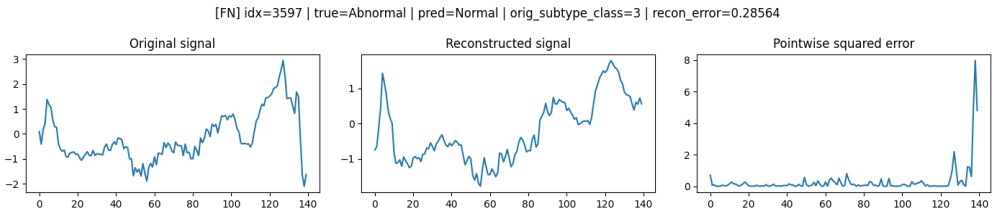
برای درک دقیق‌تر منشأ خطاهای مدل، در این بخش یک نمونه از خطای مثبت کاذب و یک نمونه از خطای منفی کاذب بررسی شده است. این تحلیل نشان می‌دهد که خطای بازسازی، اگرچه شاخص مفیدی برای تشخیص ناهنجاری است، اما نمی‌تواند تمام تنوع درون‌کلاسی ضربان‌های طبیعی و غیرطبیعی را به‌طور کامل تفکیک کند.



شکل۷- یک نمونه‌ی False Positive ضربان طبیعی که به‌اشتباه ناهنجاری تشخیص داده شده

در این نمونه، با شناسه idx=۱۱۸۱، برچسب واقعی ضربان طبیعی است؛ اما مدل آن را غیرطبیعی پیش‌بینی کرده است. خطای بازسازی این نمونه برابر با ۰.۹۲۵۳۷ است که به‌طور محسوسی از آستانه مدل پایه، یعنی ۰.۳۵۱۶ بیشتر است. با مشاهده سیگنال

اصلی مشخص می‌شود که این ضربان، هرچند در کلاس طبیعی قرار دارد، نسبت به الگوی رایج ضربان‌های طبیعی شکل متفاوت‌تری دارد. به‌ویژه، فرورفتگی عمیق‌تر و تغییرات موضعی بیشتری در بخش میانی سیکل دیده می‌شود. اتوانکودر فقط با داده‌های طبیعی آموزش دیده است و عمدتا الگوی غالب یا میانگین فضای طبیعی را فرا گرفته است؛ بنابراین، در بازسازی نمونه‌های طبیعی اما کم‌تکرار یا دارای شکل متفاوت، خطای بیشتری تولید می‌کند. نمودار خطای نقطه‌ای نیز نشان می‌دهد که اختلاف مدل با سیگنال واقعی صرفا در یک نقطه متمرکز نیست، بلکه در چند بخش از ضربان، به‌ویژه در نواحی دارای تغییرات سریع، افزایش یافته است. بنابراین، این False Positive را می‌توان نتیجه محدود بودن توان مدل برای پوشش تنوع طبیعی در داده‌های کلاس ۱ دانست.



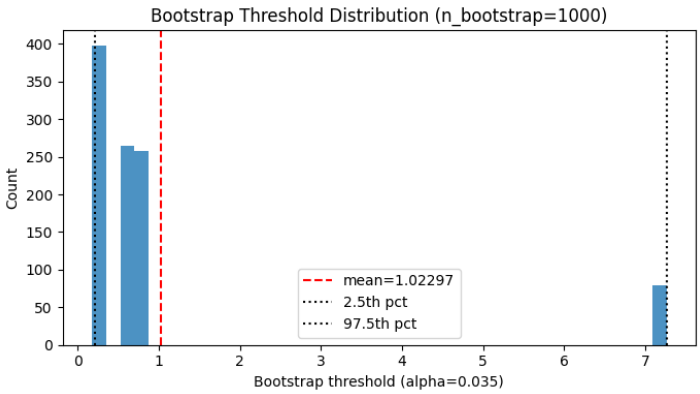
شکل۱۱- یک نمونه‌ی False Negative ناهنجاری (کلاس ۳) که تشخیص داده نشده

در این نمونه‌ی FN (idx=۳۵۹۷، کلاس ۳)، خطای بازسازی تنها ۰٫۲۸۶ است پایین‌تر از baseline_p۹۵. سیگنال اصلی و بازسازی‌شده تقریبا یکسان به‌نظر می‌رسند، به‌جز یک اختلافِ کوچک نزدیک انتهای سیگنال (نمونه‌های ۱۳۰ تا ۱۴۰). این دقیقاً مصداق پارادوکسِ مورد است: اتوانکودر این ناهنجاری خاص را به‌اندازه‌ی کافی خوب بازسازی کرده که زیر رادار بماند.

جدولِ ۱۰ نمونه‌ی FN با پایین‌ترین خطا (نزدیک‌ترین به مرز threshold) نشان می‌دهد اکثرِ این‌ها از کلاس‌های ۲، ۳ و ۵ هستند همان کلاس‌هایی که در شکلِ ۵ بیشترین افتِ Recall را در thresholdهای بالاتر داشتند.

۶.۱۰ تحلیل پایداری آستانه با Bootstrap

از آنجا که آستانه پیشنهادی بر پایه مجموعه validation-normal تعیین می‌شود و این مجموعه فقط شامل ۵۹ نمونه است، پایداری آستانه با استفاده از روش Bootstrap بررسی شد. در این تحلیل، ۱۰۰۰ نمونه‌گیری با جایگذاری از داده‌های اعتبارسنجی طبیعی انجام شد و آستانه متناظر با α=۰.۰۳۵ برای هر نمونه Bootstrap محاسبه گردید.



شکل ۱۲- توزیع bootstrap برای T*(α=۰٫۰۳۵)، با n_bootstrap=۱۰۰۰

جدول ۹ — آمار توصیفی توزیع Bootstrap آستانه برای α=۰٫۰۳۵

آماره	مقدار
میانگین	۱٫۰۲۲۹۷
میانه	۰٫۵۲۸۳۷
انحراف‌معیار	۱٫۸۳۸۵۱
بازه‌ی ۹۵٪ (صدکی)	[۰٫۲۱۶۶۳ ,۷٫۲۷۰۰۶]
پهنای بازه	۷٫۰۵۳۴۳

نتایج Bootstrap یک نکته مهم و نگران‌کننده را آشکار می‌کند: توزیع آستانه نه‌تنها حول مقدار میانه متمرکز نیست، بلکه ساختاری چندوجهی دارد. میانه آستانه برابر با۰.۵۲۸۳۷ است، اما در بخشی از نمونه‌گیری‌های Bootstrap، آستانه به مقدار بسیار بزرگ‌تری، نزدیک به ۷.۲۷۰۰۶، منتقل شده است.

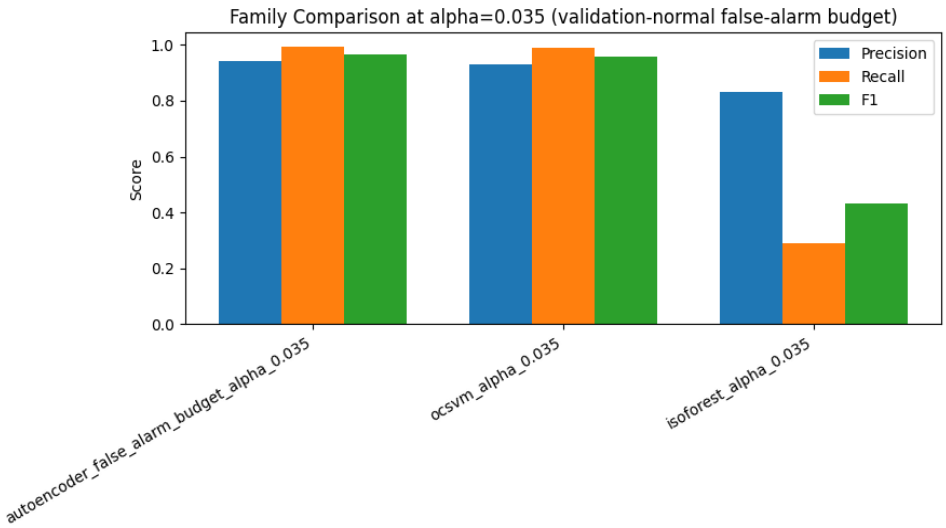
به‌طور مشخص، مقدار نزدیک به ۷.۲۷ در ۷۹ مورد از ۱۰۰۰ تکرار Bootstrap، معادل ۷.۹٪ از نمونه‌ها، رخ داده است. چنین آستانه‌ای در عمل بسیار سخت‌گیرانه خواهد بود و بخش زیادی از نمونه‌های غیرطبیعی را طبیعی طبقه‌بندی می‌کند. در نتیجه، اگر ترکیب محدود مجموعه اعتبارسنجی طبیعی اندکی متفاوت بود، امکان انتخاب آستانه‌ای بسیار بزرگ‌تر از مقدار مشاهده‌شده وجود داشت؛ آستانه‌ای که می‌توانست Recall مدل را به‌شدت کاهش دهد. بنابراین، اگرچه قاعده بودجه هشدار کاذب از نظر مفهومی شفاف و قابل‌تفسیر است، پایداری عملی آن به اندازه و نمایندگی مجموعه اعتبارسنجی طبیعی وابستگی بالایی دارد. مهم‌ترین علت بی‌ثباتی مشاهده‌شده، تعداد کم نمونه‌های validation-normal، یعنی فقط ۵۹ نمونه، است. در چنین حجم کوچکی، یک یا چند نمونه دارای خطای بازسازی بالا می‌توانند به‌طور نامتناسب بر صدک‌های بالایی و در نتیجه بر آستانه نهایی اثر بگذارند. این یافته باید در بخش محدودیت‌های پژوهش برجسته شود. برای استفاده عملی‌تر از روش پیشنهادی، می‌توان از مجموعه اعتبارسنجی طبیعی بزرگ‌تر، اعتبارسنجی متقاطع، یا روش‌های مقاوم‌تر برای برآورد صدک‌های دنباله توزیع استفاده کرد.

۷.۱۰ مقایسه با الگوریتم‌های یادگیری ماشین کلاسیک

برای ارزیابی قدرت مدل پیشنهادی، دو الگوریتم کلاسیک تشخیص ناهنجاری، یعنی One-Class SVM (OCSVM)و Isolation Forest (IF)، به‌عنوان خط‌مبنا (Baseline) انتخاب شدند. هر دو مدل فقط روی داده‌های train-normalآموزش دیدند. برای OCSVM از هسته RBF با پارامتر nu=۰٫۰۵ و برای Isolation Forest از ۲۰۰ درخت استفاده شد. نکته کلیدی این است که برای مقایسه عادلانه، آستانه تصمیم‌گیری هر سه مدل با استفاده از همان قاعده پیشنهادی پژوهش ((T*(α)) روی مجموعه اعتبارسنجی تنظیم شده است.

جدول ۱۰- نتایج مقایسه‌ای سه مدل در بودجه هشدار کاذب

روش	A	Precision	Recall	F۱
Autoencoder	۰٫۰۳۵	۰٫۹۴۲۸	۰٫۹۹۴۱	۰٫۹۶۷۸
One-Class SVM	۰٫۰۳۵	۰٫۹۲۸۹	۰٫۹۹۰۹	۰٫۹۵۸۹
Isolation Forest	۰٫۰۳۵	۰٫۸۳۳۳	۰٫۲۹۱۰	۰٫۴۳۱۳



همانطور که در جدول ۱۰ مشاهده می‌شود اتوانکودر و OCSVM عملکرد بسیار نزدیک و درخشانی (F۱score- بالای ۰.۹۵) از خود نشان دادند. این موضوع تأیید می‌کند که هر دو مدل موفق شده‌اند مرزهای فشرده و دقیقی پیرامون توزیع ضربان‌های طبیعی در فضای ویژگی‌های سیگنال ایجاد کنند. این مدل با وجود استفاده از همان قاعده آستانه‌گذاری، عملکرد بسیار ضعیفی (Recall معادل ۲۹٪) داشت. علت این موضوع را می‌توان در ماهیت داده‌های ECG جستجو کرد؛ Isolation Forest برای داده‌های جدولی (Tabular) با ویژگی‌های مستقل طراحی شده است و در فضای خام ۱۴۰ بعدی سیگنال‌های زمانی که دارای همبستگی شدید موضعی هستند، قادر به جداسازی مؤثر ناهنجاری‌ها نیست. همچنین سخت‌گیرانه‌تر شدن بودجه خطا (مثلاً در α=۰.۰۲)، افت حساسیت در OCSVM سریع‌تر از اتوانکودر رخ می‌دهد. این مشاهده نشان می‌دهد که اگرچه قاعده آستانه‌گذاری کنترل صریحی روی FPR می‌دهد، اما نرخ نهایی Recall به‌شدت به توانایی مدل در نگاشت ویژگی‌های ناهنجار به خارج از محدوده آستانه بستگی دارد.

۱۱. تحلیل انتقادی، محدودیت‌ها و صداقت علمی

۱.۱۱ تأیید فرضیات پژوهش

در طراحی اولیه این پژوهش، فرضیه اصلی این بود که قاعده $T^*(\alpha)$ می تواند به صورت سیستماتیک و قابل پیش بینی، یک trade-off بین کنترل هشدار کاذب و حفظ Recall ایجاد کند. نتیجه صریح این شد که برخلاف دو گزارش قبلی (RNN-Jena و ViT/CNN)، این بار فرضیه اصلی به وضوح تایید شد.همچنین یک الگوی کاملا یکنواخت و monotonic نشان دادند که با کم شدن α از ۰/۱۰ به ۰/۰۲، Precision به طور پیوسته از ۸۶/۳٪ به ۹۵/۷٪ افزایش پیدا کرد و Recall هم به طور پیوسته از ۹۹/۹٪ به ۹۸/۱٪ کاهش یافت، بدون این که هیچ نقطه نامنظم یا خلاف جهتی دیده شود. فرضیه فرعی هم درست از آب در آمد؛ هزینه این سخت گیری به طور نامتناسب روی کلاس های ۳ و ۵ افتاد (افت Recall به ترتیب ۴/۶ و ۹/۱ واحد درصد از baseline تا سخت گیرترین α)، در حالی که کلاس های ۲ و ۴ تقریبا دست نخورده باقی ماندند. با این حال، این تایید مثبت نباید به معنی

این خوانده شود که همه چیز عالی است، چون دو یافته خلاف انتظار وجود دارد که اعتماد به نتیجه را محدود می کند. اول این که پایداری آماری خود threshold خیلی ضعیف است؛ تحلیل bootstrap نشان داد threshold انتخاب شده برای همان ۰/۰۳۵= α در ۷/۹٪ از نمونه های bootstrap می توانست ۱۴ برابر بزرگ تر باشد (۷/۲۷ به جای ۰/۵۳). به عبارت دیگر، خود قاعده درست است، اما عدد مشخصی که این قاعده روی همین validation-set خاص تولید کرده، شکننده است. دوم این که در۰/۰۵ =αو ۰/۰۳۵= α دقیقا یک threshold یکسان به دست آمد و این نشان می دهد با۵۹ =n فقط چند مقدار گسسته از FPR قابل دستیابی است و قاعده نمی تواند به صورت پیوسته تنظیم شود.

۱۱. ۲ تحلیل علل ریشه ای

پشت این رفتارها چهار دلیل اصلی وجود دارد. دلیل اول، هم پوشانی ذاتی توزیع ها است؛ طبق شکل ۶، حدود ۸۹٪ از نمونه های طبیعی و ۹۹٪ از نمونه های غیرطبیعی در یک بازه هم پوشان مشترک قرار دارند. این هم پوشانی یک محدودیت ذاتی داده است، نه ضعف threshold، و هیچ انتخابی برای آستانه هر قدر هم هوشمندانه نمی تواند آن را از بین ببرد؛ فقط می تواند محل trade-off را جا به جا کند. دلیل دوم، کوچک بودن مجموعهvalidation-normal =nاست که در واقع عامل اصلی بی ثباتی bootstrap به حساب می آید. با فقط ۵۹ نمونه، صدک ۹۵ (یا هر α مشابه) به یکی دو نمونه مرزی حساس است و یک نمونه پرت (outlier) در validation می تواند threshold را به شدت جا به جا کند؛ دقیقا همان چیزی که مد ۷/۲۷ در bootstrap نشان داد. دلیل سوم، عدم توازن شدید subtype ها است؛ کلاس ۵ در test فقط ۲۲ نمونه دارد و یک تغییر کوچک در تعداد FN (مثلا از ۲ به ۴ نمونه) باعث جهش بزرگ در Recall گزارش شده می شود (از ۹۰/۹٪ به ۸۱/۸٪). یعنی بخشی از الگوی افت نامتناسب کلاس ۵ می تواند نویز آماری ناشی از همین نمونه کوچک باشد، نه صرفا دشواری ذاتی این subtype. دلیل چهارم، ظرفیت باقیمانده در گلوگاه ۸ بعدی است؛ با این که این بطری گردن نسبتا کوچک است، نمونه FN بررسی شده (idx=۳۵۹۷) نشان داد اتوانکودر می تواند بعضی ناهنجاری های ظریف را به اندازه کافی خوب بازسازی کند، ناهنجاری هایی که انحرافشان فقط در بخش کوچکی از سیگنال بود (اینجا نزدیک نمونه های ۱۳۰ تا ۱۴۰).

۱۱. ۳ محدودیت های پژوهش

مهم ترین محدودیت این پژوهش این است که مجموعه validation-normal خیلی کوچک است(n=۵۹)؛ این محدودیت اصلی کل پژوهش به حساب می آید و مستقیما پایداری threshold را تضعیف می کند. علاوه بر این، گزارش Recall به تفکیک subtype برای کلاس ۳ (=n۸۶) و به ویژه کلاس ۵ (n=۲۲) روی نمونه خیلی کوچکی استوار است و فاصله اطمینان این اعداد گزارش نشده، بنابراین باید با احتیاط تفسیر شوند. نکته بعدی این است که Isolation Forest بدون تنظیم فراپارامتر یا مهندسی ویژگی اختصاصی ارزیابی شد؛ در نتیجه عملکرد ضعیف آن ممکن است بازتاب نامناسب بودن آن روی این نوع داده باشد، نه یک نتیجه گیری قطعی درباره کل خانواده isolation-based. محدودیت دیگر این است که اتوانکودر فقط یک بار آموزش دید (بدون ensemble یا تکرار چند seed)، پس عدم قطعیت ناشی از خود فرایند آموزش (epistemic uncertainty) در تحلیل لحاظ نشده و فقط عدم قطعیت ناشی از انتخاب threshold (aleatoric/sampling) بررسی شده است. در نهایت، امتیاز ناهنجاری فقط reconstruction MSE است و متریک های جایگزین مثل فاصله شکل موج یا DTW اصلا آزموده نشدند.

۱۲. نتیجه گیری

این پروژه یک اتوانکودر Dense را روی ۵۰۰۰ECG آموزش داد و به جای انتخاب یک صدک ثابت دلخواه برای threshold، یک قاعده صریح و توجیه پذیر بر پایه بودجه هشدار کاذب طراحی و ارزیابی کرد. یافته نهایی این بود که برخلاف دو گزارش دیگر همین سری، این بار فرضیه اصلی با شواهد تجربی به روشنی تایید شد؛ قاعده T*(α) واقعا یک trade-off یکنواخت و قابل پیش بینی Precision/Recall می سازد و هزینه اش را به طور نامتناسب روی subtype های حساس تر (کلاس های ۳ و ۵) می گذارد، دقیقا همان طور که فرضیه فرعی پیش بینی کرده بود. اما تحلیل bootstrap یک هشدار مهم به این تایید اضافه کرد: با validation-set کوچک فعلی، خود عدد threshold به شدت ناپایدار است. بر همین اساس، توصیه عملی برای استقرار این است که α=۰/۰۳۵ (threshold≈۰/۵۳) انتخاب شود و پیش از هرگونه استقرار بالینی، حداقل ۲۰۰ تا ۳۰۰ نمونه طبیعی بیشتر برای validation جمع آوری شود.

منابع:

[۱] Chen, Y., Keogh, E., Hu, B., Begum, N., Bagnall, A., Mueen, A., & Batista, G. (۲۰۱۵). The UCR Time Series Classification Archive. https://www.timeseriesclassification.com/

[۲] Goldberger, A. L., Amaral, L. A. N., Glass, L., Hausdorff, J. M., Ivanov, P. C., Mark, R. G., Mietus, J. E., Moody, G. B., Peng, C.-K., & Stanley, H. E. (۲۰۰۰). PhysioBank, PhysioToolkit, and PhysioNet: Components of a new research resource for complex physiologic signals. *Circulation, 101*(۲۳), e۲۱۵–e۲۲۰.

[۳] Sakurada, M., & Yairi, T. (۲۰۱٤). Anomaly detection using autoencoders with nonlinear dimensionality reduction. In Proceedings of the MLSDA ۲۰۱٤ ۲nd Workshop on Machine Learning for Sensory Data Analysis.

[٤] Schölkopf, B., Platt, J. C., Shawe-Taylor, J., Smola, A. J., & Williamson, R. C. (۲۰۰۱). Estimating the support of a high-dimensional distribution. Neural Computation, *13*(۷), ۱٤٤۳–۱٤۷۱.

[٥] Liu, F. T., Ting, K. M., & Zhou, Z.-H. (۲۰۰۸). Isolation forest. In Proceedings of the IEEE International Conference on Data Mining (ICDM).

[٦] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (۲۰۱۷). Attention is all you need. In Advances in Neural Information Processing Systems (NeurIPS) ۳۰.

[۷] Efron, B., & Tibshirani, R. J. (۱۹۹٤). An introduction to the bootstrap. Chapman & Hall/CRC.

[۸] Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (۲۰۱۱). Scikit-learn: Machine learning in Python. Journal of Machine Learning Research, ۱۲, ۲۸۲٥–۲۸۳۰.

[٩] Abadi, M., Agarwal, A., Barham, P., Brevdo, E., Chen, Z., Citro, C., Corrado, G. S., Davis, A., Dean, J., Devin, M., Ghemawat, S., Goodfellow, I., Harp, A., Irving, G., Isard, M., Jia, Y., Jozefowicz, R., Kaiser, L., Kudlur, M., Levenberg, J., Mané, D., Monga, R., Moore, S., Murray, D., Olah, C., Schuster, M., Shlens, J., Steiner, B., Sutskever, I., Talwar, K., Tucker, P., Vanhoucke, V., Vasudevan, V., Viégas, F., Vinyals, O., Warden, P., Wattenberg, M., Wicke, M., Yu, Y., & Zheng, X. (٢٠١٦). TensorFlow: Large-scale machine learning on heterogeneous systems. https://www.tensorflow.org/